

Ciencia de Datos Geoespaciales

Trabajo Final

IMT2118

Gabriel Chacín Lira
Richard Aguilera Saldaña

Repositorio: https://github.com/ra-aguilera/UHI_Mobility.git

Introducción y Descripción del Problema

Islas de calor y movilidad urbana

Zonas donde la temperatura superficial es significativamente más alta debido a la acumulación de calor por diversos factores, como el entorno construido, emisión energética de maquinaria, sectores industriales, entre otros.

Este fenómeno se intensifica en ciudades como Santiago, donde la infraestructura vial, la escasez de vegetación y la condensación demográfica contribuyen al aumento térmico.

Fuente imagen 1



Introducción y Descripción del Problema

El objetivo es identificar, cuantificar y analizar espacialmente la distribución de islas de calor en Santiago entre 2015 y 2025, evaluando su correlación con variables de movilidad urbana (infraestructura vial, ciclovías, paraderos de transporte público), y visualizar los resultados mediante herramientas de análisis geoespacial.

Preguntas de investigación

- ¿Qué comunas presentan las mayores temperaturas superficiales durante el verano?
- ¿Existe relación entre la red vial (longitud total de calles) y la temperatura?

Identificación y Descripción de Datos a utilizar





- Raster (Landsat 8 Collection 2 Level 2) disponible en Google Earth Engine (30m/pixel)
 - NDVI: índice de vegetación que representa la densidad y salud del follaje
 - NDBI: índice que indica la presencia de estructuras construidas (urbano)
 - LST: temperatura superficial, derivada de la banda térmica B10
- Capas vectoriales:
 - Comunas - Fuente: IDE Chile 2023.
 - Red vial urbana: Fuente: OpenStreetMap (extraído con osmnx) Incluye calles, avenidas, autopistas.
 - Ciclovías: descargadas desde el Geoportal SECTRA. Representa infraestructura ciclista actual.
 - “Dúo” de datos de ubicación de paradas de buses y estaciones de metro, compuesto por un excel y un shapefile de las comunas de Santiago, extraído de Matrices de Viaje (Directorio de Transporte Público Metropolitano).

Procesamiento de Datos Geoespaciales

- Se descargan y preparan imágenes por estación (verano), por región (área metropolitana de Santiago) y por nubosidad ($< 20\%$), asegurando datos con condiciones similares (días despejados, misma estación).
- Se crea un composite para cada año (2015 y 2024) usando la mediana, reduciendo el efecto de imágenes atípicas.
- Se calcula la temperatura superficial (LST), la cobertura vegetal (NDVI) y la infraestructura urbana (NDBI)
- Se emplea geemap para mapear LST, NDVI y NDBI.
- Se visualizan y preparan nuestras capas vectoriales para futuros análisis.

Resultados preliminares

- Infraestructura de movilidad completa en la Región Metropolitana




Resultados preliminares

- Mapas generados con los índices NDVI, NDBI y LST correspondientes a los veranos de 2024.
- Uso de imágenes Landsat 8 filtradas por cobertura nubosas y procesadas con Google Earth Engine.


NDVI - 2024



NDBI - 2024




LST - 2024




Resultados preliminares

- Mapas generados con los índices NDVI, NDBI y LST correspondientes a los veranos entre el 2015 al 2024 y con un AOI acotado a la provincia de Santiago.
- NDVI, NDBI : Escala típica -1 a +1, mientras más oscuro es el color indica mayor vegetación (NDVI) o alta presencia de edificaciones (NDBI) y viceversa.
- LST (temperatura superficial terrestre): Grados Celsius, para grados menores las tonalidades se presentan en azul y verde, para grados mayores son amarillo, naranja y rojo.


NDVI 2015



NDBI 2015



LST 2015





Resultados

- GeoDataFrame: Se obtiene un GeoDataFrame integrado de la Región Metropolitana a nivel comunal, el cual consolida información geoespacial relevante para el análisis de islas de calor y movilidad urbana:
 - Nombre de la comuna.
 - Superficie en KM².
 - Media del LST (temperatura superficial terrestre): 2015 y 2024.
 - Media del NDVI (índice de vegetación): 2015 y 2024.
 - Media del NDBI (índice de edificación): 2015 y 2024.
 - Longitud de ciclovías (en km).
 - Longitud de red vial (en km).
 - Cantidad de paraderos o estaciones de transporte público.

	COMUNA	SUPERFICIE	geometry	LST_mean_2015	LST_mean_2016	LST_mean_2017	LST_mean_2018	LST_mean_2019	LST_mean_2020	LST_mean_2021	...	NDVI_mean_2023	NDBI_mean_2023	NDVI_mean_2024	NDBI_mean_2024	longitud_km_vial	longitud_km_ciclovía	cantidad_paradas	densidad_ciclovía	densidad_vial	paraderos_por_km2
0	SAN MIGUEL	9.63	POLYGON ((-70.65492 -33.47644, -70.65377 -33.4...	31.763966	32.069544	36.859876	31.634820	35.396058	33.702273	35.636019	...	0.068765	0.020849	0.074239	0.017565	241.473252	35.705928	187.0	3.707781	25.075104	19.418484
1	MACUL	12.81	POLYGON ((-70.59021 -33.51035, -70.59069 -33.5...	31.241332	31.424023	36.479027	32.148039	35.222952	33.922409	35.613154	...	0.083981	0.010168	0.089956	0.006438	396.822074	38.939326	279.0	3.039760	30.977523	21.779859
2	MAIPÚ	136.81	POLYGON ((-70.72199 -33.47321, -70.72214 -33.4...	34.666477	33.404768	38.875193	33.848736	39.640987	36.496527	37.950965	...	0.137449	-0.001067	0.135780	0.004495	1862.513634	84.113496	812.0	0.614820	13.613871	5.935239
3	PROVIDENCIA	14.45	POLYGON ((-70.63156 -33.44983, -70.63163 -33.4...	29.324667	29.117910	34.117743	30.289908	33.026441	31.589555	33.775035	...	0.104674	-0.023364	0.114471	-0.031324	580.124592	67.112936	258.0	4.644494	40.147031	17.854671
4	SAN RAMÓN	6.32	POLYGON ((-70.65495 -33.55497, -70.65449 -33.5...	31.220449	32.391157	36.763392	31.581269	36.120530	34.965282	35.927621	...	0.059913	0.046188	0.064299	0.044095	215.818739	15.504820	202.0	2.453294	34.148535	31.962025

Resultados Diferencias Interanuales

- El fenómeno de islas de calor está presente en todas las zonas, pero con distinta intensidad interanual. Las zonas Poniente y Norte presentan más variabilidad térmica, mientras que Centro y Sur son más estables
 - Todos los sectores muestran una disminución de LST en 2024 respecto a 2023.
 - Mayor vegetación o cambios en uso de suelo.
 - Implementación de infraestructura verde o expansión urbana que afecta la absorción térmica.



Resultados Regresión Espacial



- Existe una fuerte dependencia espacial en la distribución de la temperatura superficial urbana (LST), especialmente en 2024.
- El tamaño de la comuna aparece como un factor relevante: comunas más grandes tienden a tener menor LST.
- Las variables asociadas a infraestructura de transporte (vialidad, ciclovías, paradas) no tienen un impacto significativo directo sobre el LST en estos modelos, lo cual sugiere que su efecto puede estar mediado por otras variables o escalas.

```
LST 2023
REGRESSION RESULTS
-----
SUMMARY OF OUTPUT: MAXIMUM LIKELIHOOD SPATIAL LAG (METHOD = FULL)
-----
Data set      : unknown
Weights matrix : unknown
Dependent Variable : dep_var      Number of Observations: 30
Mean dependent var : 33.4312      Number of Variables : 6
S.D. dependent var : 2.2304      Degrees of Freedom : 24
Pseudo R-squared : 0.7794
Spatial Pseudo R-squared: 0.7113
Log likelihood : -40.2601
Sigma-square ML : 1.1403      Akaike info criterion : 108.520
S.E of regression : 1.0678      Schwarz criterion : 116.927
-----
Variable      Coefficient      Std. Error      z-Statistic      Probability
-----
CONSTANT      5.64114          2.92899        1.92597         0.05411
var_1         0.00061          0.00099        0.60986         0.54195
var_2         0.00391          0.01141        0.34238         0.73206
var_3         -0.00226         0.00232        -0.97615        0.32899
var_4         -0.00468         0.00178        -2.62219        0.00874
M_dep_var     0.84607          0.08476        9.98184         0.00000
-----
SPATIAL LAG MODEL IMPACTS
Impacts computed using the 'simple' method.
Variable      Direct      Indirect      Total
var_1         0.0006     0.0033       0.0039
var_2         0.0039     0.0215       0.0254
var_3         -0.0023    -0.0124      -0.0147
var_4         -0.0047    -0.0257      -0.0304
-----
END OF REPORT
-----
```

```
LST 2024
REGRESSION RESULTS
-----
SUMMARY OF OUTPUT: MAXIMUM LIKELIHOOD SPATIAL LAG (METHOD = FULL)
-----
Data set      : unknown
Weights matrix : unknown
Dependent Variable : dep_var      Number of Observations: 30
Mean dependent var : 32.2252      Number of Variables : 6
S.D. dependent var : 2.0405      Degrees of Freedom : 24
Pseudo R-squared : 0.8137
Spatial Pseudo R-squared: 0.0090
Log likelihood : -44.0033
Sigma-square ML : 0.8541      Akaike info criterion : 101.367
S.E of regression : 0.9242      Schwarz criterion : 109.774
-----
Variable      Coefficient      Std. Error      z-Statistic      Probability
-----
CONSTANT      3.58726          2.12678        1.68670         0.09166
var_1         0.00082          0.00086        0.95575         0.33928
var_2         0.00886          0.00986        0.89883         0.36874
var_3         -0.00263         0.00199        -1.32031        0.18073
var_4         -0.00300         0.00154        -2.07423        0.03806
M_dep_var     0.89200          0.06417        13.90006        0.00000
-----
SPATIAL LAG MODEL IMPACTS
Impacts computed using the 'simple' method.
Variable      Direct      Indirect      Total
var_1         0.0008     0.0068       0.0076
var_2         0.0089     0.0732       0.0820
var_3         -0.0026    -0.0217      -0.0244
var_4         -0.0032    -0.0265      -0.0297
-----
END OF REPORT
-----
```

Resultados Autocorrelación Espacial

- Existe un patrón espacial claro en la distribución de la temperatura superficial (LST), evidenciado por un valor de Moran's I > 0.6 con significancia estadística ($p < 0.01$) tanto en 2023 como 2024.
- Comunas con altas LST están agrupadas entre sí, lo mismo ocurre con comunas de bajas temperaturas, lo que indica una autocorrelación espacial positiva fuerte



Conclusión