

Islas de calor y movilidad urbana

El efecto isla de calor urbana (UHI) ocurre cuando ciertas áreas urbanizadas acumulan calor y presentan temperaturas de superficie más altas que sus alrededores rurales debido a factores como la densidad edificada, el asfalto o la falta de vegetación. Estudios en Santiago de Chile muestran que la ciudad es sistemáticamente más cálida que su entorno, con intensidades promedio de UHI de alrededor de 0,8–2 °C según la temporada. En particular, las comunas centrales y oriente (ej. Santiago, Providencia, Ñuñoa, Las Condes) concentran los mayores valores de temperatura superficial, reflejando la mayor densidad de infraestructura construida, especialmente notable en verano.

Las consecuencias de las UHI incluyen mayor demanda energética (aire acondicionado), riesgos para la salud (estrés térmico) y deterioro de la calidad del aire. En Santiago, la combinación de clima mediterráneo seco, alta densidad poblacional y escasez de vegetación urbana intensifica este fenómeno.

Derivándonos de dicha problemática, el proyecto **UHI Mobility** se centra en analizar UHI en Santiago y su relación con variables de movilidad urbana. Los objetivos generales incluyen identificar, cuantificar y mapear espacialmente las islas de calor superficiales en Santiago entre 2015 y 2024, y estudiar su correlación con la infraestructura de transporte (calles, ciclovías, paraderos). Entre las preguntas específicas se plantean: ¿Qué comunas presentan las temperaturas superficiales más altas en verano? ¿Cómo se relaciona la longitud total de la red vial o la cobertura de ciclovías con la temperatura superficial?

Para fundamentar el estudio se parte de la literatura existente sobre UHI; por ejemplo, se sabe que las zonas con alta urbanización tienden a agrupar temperaturas anormalmente altas, lo que justifica investigar patrones espaciales de autocorrelación y la influencia de infraestructuras (como calles y paraderos) en el patrón térmico urbano.

1. Objetivos generales y específicos

- a. **Objetivo general:** Caracterizar y analizar el fenómeno de islas de calor superficiales en la Provincia de Santiago (2015–2024) en relación con la movilidad urbana y la infraestructura asociada.
- b. **Objetivos específicos:**
 - i. **Mapear índices geoespaciales clave** (NDVI, NDBI, LST) para cada año usando imágenes Landsat 8 preprocesadas.
 - ii. **Determinar patrones espaciales y diferencias interanuales** de temperatura superficial urbana (LST) identificando comunas y zonas con cambios significativos.
 - iii. **Analizar la influencia de infraestructura de movilidad** examinando estadísticamente si la longitud de calles, existencia de ciclovías o paraderos de transporte público se asocian con variaciones en la temperatura superficial.
 - iv. **Evaluar modelos espaciales** construyendo regresiones espaciales para explicar la distribución de LST considerando variables de red

vial, e investigar la autocorrelación espacial de LST mediante índices como Moran's I.

- v. **Visualizar los resultados** con mapas temáticos (p.ej. mapas de NDVI, NDBI, LST) y gráficos comparativos (p. ej. tendencias interanuales por zona) que permitan una mejor interpretación de los hallazgos.

2. Descripción de los datos

El estudio utiliza datos raster y vectoriales multisectoriales, detallados a continuación:

- a. **Imágenes satelitales Landsat 8 (raster):** Se emplea la colección Landsat 8 Collection 2 Level 2 disponible en Google Earth Engine, centrándose en las bandas relevantes para los índices estudiados.
 - i. **Cobertura espacial:** Área Metropolitana de Santiago (aprox. 32°–34°S, 70°–71°O) y, en análisis comparativo, la provincia de Santiago en particular.
 - ii. **Cobertura temporal:** veranos (enero a marzo) de los años 2015 a 2024, con baja nubosidad (<20%). Resolución: 30 m para las bandas multispectrales, 100 m (re-muestreo a 30) para las bandas térmicas.
- b. **Variables de interés:**
 - i. **NDVI (Índice de Vegetación de Diferencia Normalizada):** calculado como $(\text{Banda5} - \text{Banda4}) / (\text{Banda5} + \text{Banda4})$, donde B5 (infrarrojo cercano) y B4 (rojo). NDVI es un indicador de la densidad y salud del follaje; valores cercanos a +1 indican vegetación densa.
 - ii. **NDBI (Índice de Edificación):** calculado como $(\text{Banda6} - \text{Banda5}) / (\text{Banda6} + \text{Banda5})$, es decir $(\text{SWIR} - \text{NIR}) / (\text{SWIR} + \text{NIR})$. Representa presencia de superficies construidas. Valores cercanos a +1 indican más áreas pavimentadas o edificadas.
 - iii. **LST (Temperatura Superficial de la Tierra):** derivada de la Banda 10 de Landsat 8 (banda térmica), convertida a temperatura en °C siguiendo los parámetros radiométricos y constantes de Landsat. Las imágenes de LST reflejan la temperatura de la superficie, clave para identificar UHI.
- c. **Datos vectoriales:**
 - i. **Comunas:** Polígonos comunales del Gran Santiago (IDE Chile 2023). Sirven para zonificar y promediar valores de LST/NDVI por comuna.
 - ii. **Red vial:** Capa de calles, avenidas y autopistas de Santiago, obtenida de OpenStreetMap (mediante osmnx). Incluye la longitud total de la malla vial por comuna.
 - iii. **Ciclovías:** Polilíneas de ciclovías oficiales (geoportal SECTRA), representando la red ciclovitaria existente.
 - iv. **Paraderos de buses y estaciones de metro:** puntos de paradas (Directorio de Transporte Público Metropolitano, matrices de viaje).

- v. **Zonificación interna:** En análisis adicional se agruparon comunas en zonas (Norte, Centro, Sur, Oriente, Poniente) para evaluar tendencias regionales.

3. Desarrollo (Procesamiento de datos)

El procesamiento de datos siguió los siguientes pasos, aprovechando Google Earth Engine (GEE) y herramientas Python (geopandas, matplotlib, PySAL, entre otros):


- a. **Preparación de imágenes Landsat:** Se filtraron las colecciones de Landsat 8 por ubicación (Provincia de Santiago), fecha (veranos 2015–2024) y calidad (nubosidad < 20%). Para cada año se generó un composite de verano usando la mediana de píxeles, evitando valores atípicos. A cada composite se calculó un arreglo multibanda en GEE incluyendo NDVI, NDBI y LST.
- b. **Visualización en GEE:** Con la librería **geemap**, se visualizaron los composites anuales. Se definieron parámetros de visualización: por ejemplo, para LST se aplicó una paleta de color que va del azul (frío) al rojo (cálido), facilitando identificar áreas calientes (un procedimiento inspirado en estudios previos). Los mapas finales mostraron NDVI, NDBI y LST para cada año en la zona de estudio.
- c. **Extracción de estadísticas zonales:** Se descargaron los composites de LST y NDVI por año como imágenes raster de referencia, y se intersecaron con la capa de comunas. Se usó el método `ee.Reducer` de EE para calcular la media de LST y NDVI en cada comuna y año. Así se obtuvo una tabla con, por cada comuna y año, valores promedio de LST y NDVI. Estos valores se fusionaron en un `GeoDataFrame`.
- d. **Cálculo de diferencias interanuales:** Se generaron variables de cambio anual: $\Delta LST_{year} = LST_{year} - LST_{(year-1)}$ y similar para NDVI, para cada año de 2015 a 2024. Se agrupan totales por zona (p. ej. media por zona Norte, Centro, etc.) definidas manualmente (de manera informal y generalizada), permitiendo graficar la evolución térmica por región.
- e. **Modelamiento estadístico:**
 - i. **Regresión espacial:** Se probaron modelos de regresión lineal espacial usando PySAL y `spreg`, para predecir LST dado el tamaño comunal y variables de movilidad, para identificar correlaciones en las variables de infraestructura de transporte que expliquen variaciones en LST.
 - ii. **Autocorrelación espacial:** Se calculó el índice de Moran global sobre la media de LST comunal para cada año. Moran's I mide la autocorrelación espacial: valores cercanos a +1 indican que altas temperaturas están agrupadas espacialmente. También se exploraron mapas de Moran local o G_i^* (zonas calientes/frías). Estos análisis confirman hasta qué punto existe dependencias espaciales (por ejemplo, si una comuna cálida tiende a rodearse de comunas cálidas).

- f. **Herramientas:** Se utilizó Google Earth Engine para el procesamiento masivo de imágenes (cálculos NDVI, NDBI, LST y reducciones zonales). Para el análisis vectorial y de regresión se emplearon pandas, geopandas (manipulación de shapefiles y datos tabulares), PySAL (estadística espacial) y matplotlib/pyplot para gráficos. Se definieron funciones propias para organizar iteraciones anuales y generar visualizaciones comparativas (ver notebook).

4. Resultados y conclusiones

Los resultados principales se ilustran con mapas y gráficos clave:

- a. **Mapas de índices (2024):** En base a los mapas generados con capas (NDVI), (NDBI) y (LST), podemos notar las claras relaciones entre la vegetación, el urbanismo y la temperatura superficial, siendo visualmente comprobable que zonas centrales con alto nivel de urbanismo como Santiago o Estación Central, mantienen temperaturas moderadamente altas en general; zonas al este como Las Condes o Lo Barnechea, con un nivel levemente inferior de urbanismo y uno favorable de vegetación (y posiblemente por su extensión y ser más cercanas a la cordillera), mantienen temperaturas más bajas a comparación; finalmente zonas como Quilicura o Pudahuel con un nivel medianamente bajo (en relación a su extensión) de urbanismo y vegetación sostienen altas temperaturas en comparación al resto.
- b. **Diferencias interanuales:** El análisis de ΔLST y $\Delta NDVI$ en general muestra fluctuaciones a lo largo de los años, como **aumentos de LST** en los años 2017, 2019 y 2020 en la mayoría de zonas, lo asociamos a eventos meteorológicos externos al estudio, por ejemplo, el fenómeno de “El Niño”, también se puede evidenciar la relevancia del índice de vegetación respecto a la temperatura superficial (p. ej. Los años 2020 y 2022). Es notable que zonas como la céntrica presentan menores fluctuaciones, debido a su estructura urbana, difícilmente existen cambios que, a tan corto plazo, puedan influenciar en la misma medida que otras zonas periféricas con distintas posibilidades en el uso del suelo.



- c. **Regresión espacial:** Los modelos lineales espaciales indicaron que el área de la comuna tiene efecto significativo negativo sobre LST (comunidades más grandes tienden a promediar temperaturas menores, posiblemente influenciado por comunas como Lo Barnechea). En cambio, las variables de infraestructura (longitud de calles, ciclovías, número de paraderos) no mostraron efectos significativos en el modelo, posiblemente por la extensión de los mismos o su distribución a lo largo de área de estudio, o simplemente puede que su impacto no sea tan significativo como otros posibles factores a evaluar, como la distribución demográfica.

```


LST 2024
REGRESSION RESULTS
-----

SUMMARY OF OUTPUT: MAXIMUM LIKELIHOOD SPATIAL LAG (METHOD = FULL)
-----
Data set      : unknown
Weights matrix : unknown
Dependent Variable : dep_var      Number of Observations: 30
Mean dependent var : 35.8158      Number of Variables   : 6
S.D. dependent var : 2.1247       Degrees of Freedom    : 24
Pseudo R-squared : 0.7867
Spatial Pseudo R-squared: 0.0253
Log likelihood  : -47.6962
Sigma-square ML : 1.0612          Akaike info criterion : 107.392
S.E of regression : 1.0302       Schwarz criterion     : 115.800

-----
Variable      Coefficient      Std.Error      z-Statistic      Probability
-----
CONSTANT      4.58961          2.60456        1.76215          0.07804
var_1         0.00021          0.00095        0.22500          0.82198
var_2         0.00742          0.01100        0.67440          0.50006
var_3        -0.00193          0.00221       -0.87404          0.38210
var_4        -0.00152          0.00172       -0.88649          0.37535
...
var_2         0.0074          0.0536         0.0611           0.94999
var_3        -0.0019          0.0140        -0.0159           0.98771
var_4        -0.0015          0.0110        -0.0125           0.98911
===== END OF REPORT =====

```

- d. **Autocorrelación espacial:** El índice de Moran calculado para LST fue consistentemente alto y significativo ($I > 0.6$, $p < 0.01$) en 2023 y 2024, confirmando que las altas temperaturas se concentran geográficamente (patrón de clusters). Los gráficos de autocorrelación (Local Moran, G_i^*) mostraron “hot-spots” (comunas con alta LST rodeadas de altas LST) en el poniente de la ciudad, y zonas frías (centrales y orientes más verdes) agrupadas, evidenciando autocorrelación espacial positiva fuerte.



- e. **Conclusiones:** Los objetivos del proyecto se cumplieron cierta medida. Se identificaron las comunas y zonas más cálidas y se cuantificó su evolución temporal, corroborando la hipótesis de que las UHI están ligadas a la densidad edificada y la falta de vegetación, en nuestro caso, más la falta de vegetación. Si bien la infraestructura de movilidad no mostró una relación estadística directa con LST en los modelos empleados, esto abre preguntas para estudios futuros y propuestas de modificación, por ejemplo, analizar escalas más locales (bloques o cuadra a cuadra) o considerar variables socioeconómicas adicionales.

Bibliografía

DTP Metropolitano. (s.f.). DTP Metropolitano. Obtenido de DTP Metropolitano:
<https://www.dtpm.cl/index.php/documentos/matrices-de-viaje>

Eshetie, S. M. (15 de 03 de 2024). Scientific reports. Obtenido de Scientific reports:
<https://www.nature.com/articles/s41598-024-55121-6>

IDE Chile. (29 de 09 de 2023). IDE Chile. Obtenido de IDE Chile:
<https://www.ide.cl/index.php/noticias/actualizacion-de-la-cartografia-de-division-politica-administrativa-en-chile>

Martín-Vide, P. S. (05 de 2014). Scielo. Obtenido de Scielo:
https://www.scielo.cl/scielo.php?script=sci_arttext&pid=S0718-34022014000100009

MTT, P. d. (01 de 2025). Arcgis. Obtenido de Arcgis:
<https://www.arcgis.com/apps/dashboards/d2c380a49743480e86a628daeb696e9f>

USGS. (s.f.). Obtenido de USGS: <https://www.usgs.gov/landsat-missions/landsat-normalized-difference-vegetation-index>

USGS. (s.f.). USGS. Obtenido de USGS: <https://www.usgs.gov/landsat-missions/landsat-collection-2-surface-temperature>